



UNIVERSIDAD NACIONAL AUTÓNOMA DE MÉXICO

FACULTAD DE CIENCIAS

Proyecto: Películas Exitosas

The Movie Database — TMDB API

Introducción Analítica a la Ciencia de Datos

Módulo 8. Comunicación de Resultados

Equipo 4

Maestra:

- Claudia Ivonne Juárez Gallegos

Equipo:

- Argumedo Sandoval María Fernanda
- De la Cruz Salazar Norma Arely
- Fuentes Cacho Rodolfo
- Lugo Cruz Victor Manuel
- Mora Gutiérrez Karla Fernanda
- Sánchez Aguirre Luz Lorena

México – Ciudad de México
Septiembre del 2026

Contenido

Introducción	3
Definición del análisis	3
Selección y obtención de los datos.....	3
Consideraciones metodológicas y limitaciones de la fuente	4
Principales decisiones de limpieza	4
Depuración de registros dados los errores e inconsistencias.....	4
Calidad de los datos y tratamiento de valores faltantes	4
Revisión de valores faltantes.....	5
Análisis Exploratorio	5
Distribución de las variables numéricas.....	5
Análisis de variables categóricas	6
Análisis de características de las películas	7
Matriz de Correlación	9
Ingresos vs Variables Numéricas	9
Conclusión Análisis Exploratorio	10
Modelado	11
Preparación de los datos para el modelado	11
Primer modelo supervisado: Regresión Lineal	12
Resultados de la regresión lineal.....	13
Segundo modelo supervisado: Random Forest	14
Resultados de importancia de variables	16
Evaluación final: ingresos estimados, ROI y rentabilidad.....	16
Evaluación de la clasificación de rentabilidad	16
Resultados de la clasificación de rentabilidad	17
Comparación entre ROI real y estimado.....	17
Visualización de la matriz de confusión	18
Comparación por rangos de ROI	18
Revisión de errores película por película	19
Conclusión del modelado.....	20
Conclusión general	21

Introducción

El conjunto de datos de TMDB (The Movie Database) reúne información sobre películas de distintos géneros, años y países a nivel global, incluyendo atributos como género, fecha de estreno, presupuesto, calificaciones del público e ingresos generados.

Este conjunto de datos permite explorar y analizar los factores relacionados con el desempeño comercial de las películas y, en particular, responder a la pregunta de investigación: ¿qué características de una película están asociadas con mayores ingresos de taquilla? A partir de esta información, se busca identificar patrones y relaciones que ayuden a comprender qué factores se encuentran vinculados con un mejor desempeño en términos de recaudación.

El propósito de este trabajo es realizar un análisis exploratorio de datos, y posteriormente, desarrollar un modelo predictivo que permita identificar los principales factores asociados con los ingresos obtenidos por las películas registradas en la muestra de TMDB.

Definición del análisis

Variable Objetivo: La variable objetivo del análisis son los ingresos, correspondiente a los ingresos reportados para cada película en TMDB.

Variables explicativas: Como variables explicativas se consideran presupuesto, popularidad, tiempo_duracion, calif_promedio, num_votos, franquicia, fecha_estreno, lenguaje, generos, director, top_actores, productoras, paises_productoras y palabras_clave.

Población de interés: Corresponde a las películas registradas en TMDB que cuentan con información sobre sus características generales, recepción por parte de los usuarios y desempeño financiero.

Unidad de análisis: Corresponde a cada película individual incluida en la base de datos.

Periodo de análisis: Comprende películas con fecha de estreno hasta septiembre de 2026.

Selección y obtención de los datos

Los datos utilizados en este estudio fueron obtenidos a través de la API de TMDB (The Movie Database). Inicialmente, se realizó una consulta para recuperar las 10,000 películas más populares registradas en la plataforma, ordenadas de mayor a menor popularidad. De esta consulta se obtuvo el identificador único (*id*) de cada película, el cual sirvió como referencia para realizar consultas posteriores más detalladas.

A partir de estos identificadores, se efectuaron consultas individuales a la API con el fin de recopilar información adicional sobre cada película, incluyendo variables relacionadas con su desempeño financiero, características de producción, recepción por parte del público y aspectos generales de las películas. De esta manera, se construyó la base de datos final utilizada para el análisis, integrando la información correspondiente.

La base de datos final quedó conformada por 17 variables que describen distintos aspectos de las películas analizadas. Estas variables incluyen información de identificación, popularidad, presupuesto, ingresos, duración, calificaciones otorgadas por los usuarios, características de producción y elementos asociados con

el contenido de cada película. En conjunto, estas variables permiten explorar los factores potencialmente relacionados con el desempeño comercial y los ingresos generados en la taquilla.

Consideraciones metodológicas y limitaciones de la fuente

TMDB es una fuente dinámica cuya información puede actualizarse conforme se incorporan o modifican datos de las películas, la base utilizada en este análisis debe interpretarse como una fotografía de la información disponible al momento de su extracción, y los resultados podrían variar si la consulta se realiza nuevamente en una fecha posterior.

Particularmente, la métrica de ‘popularidad’ de TMDB no corresponde a una característica fija de la película. Su cálculo considera diferentes elementos, entre ellos el número de votos y visualizaciones recientes, usuarios que agregan una película a favoritos o a su lista de seguimiento, fecha de estreno, número total de votos y el nivel de popularidad observado en días anteriores. Por lo tanto, este indicador puede modificarse a través del tiempo.

Asimismo, debido a que la muestra fue obtenida de la página donde se ordenan las películas de mayor a menor popularidad, no corresponde a una muestra aleatoria de todas las películas registradas en TMDB. En consecuencia, los resultados del análisis deben interpretarse dentro del contexto de las películas con mayor nivel de popularidad disponibles en la plataforma al momento de la extracción.

Principales decisiones de limpieza

Depuración de registros dados los errores e inconsistencias

La depuración de la base se realiza con el objetivo de conservar únicamente observaciones que cuenten con información suficiente y congruente para responder la pregunta de investigación.

Se decide eliminar las películas con presupuesto o ingresos menores a 50 dólares debido a que ambas variables son fundamentales para el análisis. En particular, los ingresos corresponden a la variable objetivo, mientras que el presupuesto constituye una de las principales variables explicativas. Mantener registros sin información válida en estas variables podría afectar la interpretación de las relaciones y el desempeño del modelo predictivo.

Asimismo, se excluyen las películas sin fecha de estreno válida o con fecha posterior a septiembre de 2026, ya que se encuentran fuera del periodo definido para el estudio o no permiten determinar correctamente su temporalidad. También se eliminan los registros con duración igual a cero o sin votos, debido a que estos valores no aportan información suficiente para analizar características relacionadas con la recepción y desempeño de las películas.

Se opta por excluir estas observaciones en lugar de imputar sus valores, ya que no existe información suficiente para estimarlos de manera confiable sin introducir supuestos adicionales que puedan sesgar los resultados.

Calidad de los datos y tratamiento de valores faltantes

Como parte de la revisión de la calidad de los datos, se identificaron y analizaron los valores faltantes y los campos vacíos de la base depurada. En el caso de las variables de texto, los campos vacíos se homologaron como valores NA para representar de manera uniforme la ausencia de información.

Al ser pocos registros los que tenían valores NA y que dicha información no era indispensable para definir la variable objetivo, ni para conservar la información financiera de las películas, se mantuvieron las observaciones correspondientes.

Revisión de valores faltantes

Como parte de la revisión de la calidad de los datos, se analizaron posibles valores atípicos en las principales variables numéricas de la base. Aunque algunas observaciones presentan valores considerablemente alejados del resto, estos pueden ser propios de las características de la industria cinematográfica y no necesariamente representan errores.



Por ello, se revisaron los valores extremos para determinar si presentaban inconsistencias. Al no identificarse anomalías evidentes, se decidió conservar los valores atípicos, ya que su eliminación podría excluir observaciones reales y relevantes para el análisis del desempeño de las películas.

Análisis Exploratorio

Distribución de las variables numéricas

Se analizó gráficamente la distribución de las variables numéricas mediante histogramas, con el fin de identificar patrones de concentración y posibles asimetrías.



Se observó que variables como ROI (Retorno de inversión), ingresos, presupuesto, número de votos y popularidad presentaron una mayor variabilidad, con la mayoría de las películas concentradas en valores bajos y algunas observaciones con valores considerablemente mayores. En cambio, calif_promedio y tiempo_duracion mostraron distribuciones más concentradas alrededor de ciertos valores, presentando un comportamiento más uniforme dentro de la muestra.



Análisis de variables categóricas

Se analizó la distribución de las principales variables categóricas de la base, considerando la pertenencia a una franquicia, el idioma original y el género de las películas. Para el género, se consideró que una misma película podría estar asociada con más de una categoría.


Los resultados mostraron una mayor concentración de películas que no pertenecían a una franquicia y una clara predominancia del inglés como idioma original. En cuanto a los géneros, Drama y Comedia presentaron una mayor frecuencia, mientras que otros tuvieron una representación menor. Esto evidenció una distribución poco equilibrada entre las distintas categorías.



Análisis de características de las películas


El listado de las películas más taquilleras muestra cómo las grandes productoras de franquicias dominan el mercado global, con títulos como Avatar, Avengers: Endgame y Spider-Man ocupando los primeros lugares gracias a su capacidad de atraer audiencias masivas y sostener campañas de marketing de enorme alcance.

La comparación entre las películas con mayores presupuestos y las más taquilleras deja ver que gastar enormes cantidades no garantiza ocupar los primeros lugares de recaudación. Clásicos como Titanic y sagas emblemáticas como Star Wars mantienen su vigencia dentro del top que más vendió entradas, lo que evidencia la fuerza de las narrativas que logran trascender los años. Asimismo, Ne Zha 2 es una película que confirma que el fenómeno no se limita a Hollywood, sino que refleja un mercado cada vez más diverso donde la escala de inversión y el impacto cultural se convierten en motores decisivos para alcanzar cifras millonarias en la taquilla: el dinero es importante, pero no suficiente para asegurar el éxito.




El gráfico de retorno sobre inversión muestra que películas de bajo presupuesto pueden convertirse en fenómenos financieros descomunales. “Actividad Paranormal” es el caso más extremo, con ganancias que multiplicaron miles de veces lo invertido, mientras que ejemplos como “El proyecto de la bruja de Blair” confirman que producciones independientes con costos mínimos pueden superar con creces a los grandes estrenos en términos de rentabilidad, teniendo en común que las películas del género de Terror tienden a ser las que presentan los ROI más altos en la industria.


Esto confirma que la eficiencia económica del cine no depende de presupuestos elevados, sino de la capacidad de ciertas propuestas para conectar con el público y generar un impacto masivo con recursos limitados.



Bajo el umbral definido de $ROI \geq 2.5$, más películas resultan no rentables que rentables, lo que evidencia el alto riesgo financiero de la industria. Aunque un ROI mayor a 1 implica recuperar lo invertido, no necesariamente significa que la producción sea considerada exitosa, ya que ese nivel apenas cubre costos sin generar beneficios reales. La diferencia entre ambos grupos refleja un mercado donde solo una parte de las producciones logra convertir su inversión en ganancias sostenibles.




El listado de actores con mayor cantidad de películas revela una trayectoria construida a partir de la participación y constancia en múltiples proyectos a lo largo del tiempo, encabezada por figuras como Robert De Niro, cuya presencia en la industria responde más a la prolificidad que al éxito comercial de taquilla. Al contrastar este perfil con el ranking de películas más taquilleras, los mayores ingresos no provienen necesariamente de los actores más recurrentes, sino de franquicias específicas capaces de movilizar audiencias masivas en torno a un puñado de títulos. Tom Holland, por ejemplo, sin figurar entre los actores con mayor número de créditos, protagoniza dos de las cintas con mayor recaudación: Spider-Man y los Vengadores. Esta desconexión entre cantidad de apariciones y éxito financiero sugiere que el desempeño en taquilla depende en mayor medida de la fuerza de la franquicia o propiedad intelectual detrás del filme que de la trayectoria individual del actor que la protagoniza.




Matriz de Correlación

Se calculó la matriz de correlación entre las variables numéricas de la base y se representó gráficamente mediante un mapa de calor.

La matriz de correlación revela que los ingresos guardan una relación notablemente fuerte con el presupuesto invertido (0.69), respaldando la intuición de que las producciones con mayor capital detrás tienden a posicionarse mejor comercialmente. El número de votos también se asocia de forma considerable con la recaudación, reflejando que las cintas con mayor alcance de audiencia suelen traducirse en un desempeño financiero superior. La popularidad muestra una conexión moderada tanto con los ingresos como con el presupuesto, señal de que factores de visibilidad y marketing influyen parcialmente en el éxito comercial sin ser determinantes por sí solos. La calificación promedio apenas se relaciona con el presupuesto, indicando que la calidad percibida por el público responde a criterios distintos a los meramente económicos.



Ingresos vs Variables Numéricas



El presupuesto de producción constituye la variable con mayor asociación positiva respecto a los ingresos, tal como lo confirma su correlación más alta dentro de la matriz: la pendiente pronunciada de su tendencia muestra que inversiones cercanas a los 600 millones de dólares se traducen consistentemente en recaudaciones superiores a los 2,000 millones de dólares. El número de votos exhibe un patrón semejante, aunque con mayor dispersión, lo cual sugiere que la exposición del público se vincula de forma considerable con el desempeño financiero. La popularidad presenta una relación positiva menos definida, pues la mayoría

de las observaciones se concentra en valores bajos, mientras algunos casos con puntuaciones extremas, superiores a 400, no logran reflejar ingresos proporcionalmente altos, restando fuerza predictiva a esta métrica. La duración del filme, al igual que la calificación promedio, exhibe una línea de tendencia prácticamente plana, señal de que ambas variables aportan escasa capacidad explicativa sobre el monto recaudado: cintas con calificaciones altas o duraciones extensas no necesariamente alcanzan cifras de taquilla elevadas.

Conclusión Análisis Exploratorio

El análisis exploratorio de datos revela un panorama amplio sobre cómo se comporta la industria cinematográfica en términos de inversión, ingresos y rentabilidad. Se observa que las franquicias y los grandes presupuestos no siempre garantizan el éxito en taquilla, mientras que producciones independientes con costos mínimos han logrado retornos extraordinarios. Al mismo tiempo, la mayoría de las películas no alcanzan el umbral de rentabilidad definido con el retorno de inversión ROI, lo que confirma que el riesgo financiero es alto y que recuperar lo invertido no basta para considerar un proyecto exitoso.

Factores como idioma, género, palabras clave y popularidad muestran patrones claros: predominio del inglés, concentración en géneros tradicionales como drama y comedia, y recurrencia de adaptaciones de otra fuente o de lugares reconocidos.

Estos hallazgos ofrecen una base sólida para construir un modelo que prediga la rentabilidad de una película. Las variables de presupuesto, popularidad, número de votos, pertenencia a franquicia, género y palabras clave aportan señales relevantes que, combinadas, permiten estimar si un proyecto tiene probabilidades de superar el umbral de rentabilidad. El reto está en capturar estas relaciones de manera eficiente, evitando depender únicamente de la inversión y considerando la interacción entre factores culturales, narrativos y de mercado que determinan el desempeño económico del cine.

Modelado

En esta etapa se desarrolla un modelo de aprendizaje supervisado con el objetivo de estimar los ingresos de taquilla de las películas a partir de sus características. Para ello, los ingresos se utilizan como variable objetivo, mientras que el resto de las variables seleccionadas se emplean como predictores.

La base se divide en un conjunto de entrenamiento y un conjunto de prueba, de manera que los modelos puedan aprender a partir de una parte de los datos y posteriormente evaluarse con películas que no fueron utilizadas durante el entrenamiento.

Se construyeron y compararon dos modelos supervisados: una regresión lineal múltiple y un Random Forest. Ambos modelos se evalúan mediante métricas de error y capacidad explicativa, con el propósito de identificar cuál presenta un mejor desempeño al estimar los ingresos de las películas.

Finalmente, las predicciones de ingresos obtenidas con el modelo seleccionado se utilizan para calcular un ROI estimado a partir del presupuesto de cada película. Este valor se compara con el ROI observado y se utiliza también para clasificar las películas como rentables o no rentables utilizando un umbral de ROI superior a 2.5.

Preparación de los datos para el modelado

Antes de entrenar los modelos, se realiza una preparación de los datos. A partir de la fecha de estreno se obtienen el año y el mes. Por otro lado, las variables de ingresos, presupuesto, popularidad y número de votos se transforman utilizando logaritmo base 10. Esto permite reducir las diferencias entre los valores y evitar que aquellos que son demasiado altos tengan una influencia alta en el entrenamiento del modelo.

Una vez definida la información que se utilizará, la muestra se divide aleatoriamente en dos conjuntos: 80% de las películas se destinan al entrenamiento de los modelos y el 20% restante se reserva para evaluar su desempeño con observaciones que no fueron utilizadas durante el aprendizaje. Se utiliza una semilla fija para que esta división pueda reproducirse al ejecutar nuevamente el análisis. También se revisa que la proporción de películas rentables y no rentables sea semejante entre ambos conjuntos.

Las variables como géneros, actores, productoras, países y palabras clave pueden contener varios elementos dentro de una misma película. Por ello, se identifican las categorías que aparecen con mayor frecuencia para poder utilizarlas en el modelo. Esta selección se realiza únicamente con el conjunto de entrenamiento, evitando utilizar información del conjunto de prueba durante la preparación del modelo.

Se conservan los 20 géneros, 30 directores, 50 actores, 50 productoras, 15 países productores y 50 palabras clave más frecuentes. Esta selección permite representar las características más recurrentes de la muestra sin crear una cantidad excesiva de variables para categorías que aparecen en muy pocas películas. En esta etapa, la frecuencia se utiliza solamente como criterio de selección; no implica que estas categorías sean necesariamente las más importantes para explicar los ingresos.

Creación de variables para el modelo

Una vez seleccionadas las categorías que se utilizarán en el modelado, es necesario transformar las variables de texto a un formato que pueda ser utilizado por los modelos. Variables como género, actores, productoras, países y palabras clave pueden contener varios elementos dentro de una misma película, por lo que no pueden incorporarse directamente en su forma original.

Para resolverlo, se crean variables indicadoras binarias de tipo 0/1. Cada categoría seleccionada se convierte en una nueva columna: el valor 1 indica que la película presenta esa característica y el valor 0 que no la presenta.

Por ejemplo, una película perteneciente al género Acción tendrá un valor de 1 en la variable correspondiente a este género. Esta transformación se aplica por separado a géneros, actores, productoras, países productores y palabras clave, utilizando las categorías previamente seleccionadas a partir del conjunto de entrenamiento.

En el caso de los directores se sigue una lógica similar, aunque cada película cuenta normalmente con un solo director. Por ello, se crea directamente una variable indicadora para cada uno de los directores seleccionados. De esta forma, tanto las variables que contienen múltiples elementos como aquellas con una sola categoría quedan representadas numéricamente.

Para el idioma se seleccionan los diez más frecuentes dentro del conjunto de entrenamiento. Los idiomas que no pertenecen a este grupo se agrupan en una categoría denominada "Otro". Posteriormente, el conjunto de prueba utiliza los mismos niveles definidos en entrenamiento, con el objetivo de mantener una estructura compatible entre ambas bases.

Finalmente, todas las variables indicadoras se integran nuevamente con la información original mediante el identificador de cada película. Las columnas de texto que ya fueron transformadas se eliminan y se generan dos bases finales: una para entrenamiento y otra para prueba.

Como comprobación, se revisa el número de películas, la cantidad de variables generadas y si ambas bases presentan las mismas columnas. Debido a que alguna categoría seleccionada puede estar presente en entrenamiento, pero no aparecer en ninguna película del conjunto de prueba, esta última verificación permite detectar posibles diferencias que deberán ajustarse antes de entrenar los modelos.

Después de crear las variables indicadoras, es posible que alguna categoría aparezca en el conjunto de entrenamiento, pero no esté presente en ninguna película del conjunto de prueba. En ese caso, la columna correspondiente puede existir únicamente en `train_final`, lo que impediría utilizar posteriormente el conjunto de prueba para generar predicciones.

Para evitar este problema, primero se identifican las variables que existen en entrenamiento, pero no en prueba. Estas columnas se agregan a `test_final` con valor 0, ya que su ausencia significa que ninguna película del conjunto de prueba presenta esa característica. También se verifica el caso contrario: variables presentes en prueba que no existan en entrenamiento. Si se encuentra alguna, se elimina, ya que el modelo únicamente puede trabajar con las características definidas durante el entrenamiento.

Finalmente, las columnas del conjunto de prueba se ordenan de la misma forma que las del conjunto de entrenamiento. Como comprobación, se revisa que ambas bases tengan el mismo número de variables y que sus nombres coincidan exactamente antes de continuar con el modelado.

Primer modelo supervisado: Regresión Lineal

Como primer modelo supervisado se utiliza una regresión lineal múltiple para predecir los ingresos de las películas. Para ello, los datos se dividen en un conjunto de entrenamiento y un conjunto de prueba.

Antes de entrenar el modelo, se eliminan las variables que no se utilizan para hacer predicciones. El ID y el título solo sirven para identificar las películas, mientras que los ingresos reales, el ROI y la clasificación de

rentabilidad se reservan para evaluar posteriormente los resultados. También se elimina el presupuesto original, ya que se utiliza log_presupuesto. La variable que el modelo busca predecir es log_ingresos. Para medir el desempeño se utilizan MSE, RMSE, MAE y R^2 . MSE, RMSE y MAE indican qué tan grande es el error de las predicciones, por lo que valores más bajos son mejores. R^2 indica qué tan bien el modelo explica los ingresos, por lo que valores más altos son mejores.

Antes de la regresión se crea un modelo base, que simplemente utiliza el promedio de log_ingresos del conjunto de entrenamiento como predicción para todas las películas. Esto sirve como referencia para comprobar si la regresión realmente mejora las predicciones.

Después, la regresión lineal múltiple se entrena utilizando todas las variables predictoras disponibles. El modelo aprende con los datos de entrenamiento y posteriormente realiza predicciones sobre el conjunto de prueba. Estas predicciones se comparan con los valores reales utilizando las mismas métricas, para determinar si el modelo mejora respecto al modelo base.

Finalmente, debido a que el modelo estima $\log_{10}(\text{ingresos})$, las predicciones se transforman nuevamente a dólares mediante 10^x . Esto permite comparar los ingresos reales y estimados película por película y calcular el error de cada predicción en su escala original.

Resultados de la regresión lineal

El modelo de regresión lineal se construyó utilizando 223 variables predictoras. Para saber si realmente funcionaba bien, primero se comparó con un modelo base, que simplemente asigna a todas las películas el ingreso promedio del conjunto de entrenamiento.

El modelo base obtuvo un R^2 de -0.002, lo que significa que prácticamente no logra explicar las diferencias en los ingresos de las películas del conjunto de prueba. En cambio, la regresión lineal obtuvo un R^2 de 0.583. Esto significa que el modelo logra explicar aproximadamente el 58.3% de las variaciones en log_ingresos de las películas que no utilizó durante su entrenamiento.

También se observa una mejora en los errores. El RMSE bajó de 0.827 a 0.534 y el MAE de 0.614 a 0.373. Como estos valores representan el error de las predicciones, una disminución significa que las estimaciones del modelo son más cercanas a los valores reales. Por lo tanto, utilizar las características de las películas permite hacer predicciones considerablemente mejores que utilizar únicamente el promedio.

En conclusión, la regresión lineal mejora claramente respecto al modelo base. Sin embargo, todavía falta compararla con el segundo modelo supervisado para conocer cómo se comporta frente a otra alternativa de predicción.


```
=====
COMPARACIÓN DE MODELOS
=====
      Modelo      MSE      RMSE      MAE      R2
1  Modelo base 0.6839908 0.8270374 0.6140709 -0.001541258
2 Regresión lineal 0.2849931 0.5338475 0.3729775 0.582695611
```

Después de evaluar el desempeño de la regresión lineal, se analizan sus coeficientes con el objetivo de identificar qué variables presentan las asociaciones de mayor magnitud con los ingresos estimados.

Para cada predictor se obtiene su coeficiente, error estándar, estadístico t y valor p. El signo del coeficiente indica la dirección de la asociación: valores positivos corresponden a una relación positiva con `log_ingresos`, mientras que valores negativos indican una relación inversa, manteniendo constantes las demás variables incluidas en el modelo.

También se calcula la magnitud absoluta de cada coeficiente para ordenar las variables y facilitar su revisión. Posteriormente, se seleccionan las 25 variables con los coeficientes de mayor magnitud.

Con el propósito de facilitar la interpretación del modelo lineal, se seleccionan únicamente aquellas variables con coeficientes estadísticamente significativos ($p_value < 0.05$). Entre ellas, se eligen las 15 que presentan la mayor magnitud absoluta, con el fin de concentrar el análisis en las asociaciones más destacadas dentro del modelo.



Además, se crea una clasificación según la dirección del coeficiente, distinguiendo entre asociaciones positivas y negativas con `log_ingresos`. Para mejorar la lectura de la gráfica, los nombres de las variables se limpian y se sustituyen algunos caracteres utilizados en la codificación interna.

La visualización de los coeficientes significativos muestra que varias de las variables numéricas utilizadas por el modelo presentan asociaciones positivas con los ingresos. En particular, el presupuesto, el número de votos y la popularidad destacan entre los coeficientes positivos de mayor magnitud, lo que indica que mayores valores de estas características se encuentran asociados con mayores niveles de `log_ingresos`, manteniendo constantes las demás variables incluidas en la regresión. También se observan asociaciones relacionadas con características categóricas como idioma, género, director, actor y productora. Algunas presentan coeficientes positivos y otros negativos, lo que refleja diferencias dentro de la muestra una vez consideradas simultáneamente las demás características de las películas.

Segundo modelo supervisado: Random Forest

Como segundo modelo supervisado se utiliza Random Forest para estimar `log_ingresos`. A diferencia de la regresión lineal, este método puede capturar relaciones no lineales e interacciones más complejas entre las características de las películas sin necesidad de especificarlas de forma manual.

El modelo se entrena utilizando el mismo conjunto de entrenamiento y las mismas variables predictoras empleadas anteriormente, lo que permite realizar una comparación directa entre ambos métodos. Se utiliza una semilla fija para mantener la reproducibilidad del análisis y se construyen 500 árboles de decisión. Además, se activa el cálculo de importancia de variables para analizar posteriormente qué características aportan más información a la capacidad predictiva del modelo. Una vez entrenado, Random Forest genera predicciones para las películas del conjunto de prueba. Estas predicciones se evalúan mediante las mismas

métricas utilizadas anteriormente: MSE, RMSE, MAE y R^2 . De esta manera, el modelo base, la regresión lineal y Random Forest pueden compararse bajo los mismos criterios.

El modelo con mejor desempeño será aquel que presente menores valores de error y un mayor R^2 en el conjunto de prueba. Esta comparación se realiza utilizando `log_ingresos`, ya que corresponde a la variable objetivo con la que fueron entrenados los modelos. Finalmente, las predicciones de Random Forest se transforman nuevamente a dólares mediante 10^x . Esto permite obtener un ingreso estimado para cada película y comparar posteriormente estos valores con los ingresos reales y con el presupuesto de producción.

El modelo Random Forest se construyó utilizando 500 árboles de decisión. En cada división de los árboles se evaluaron aleatoriamente 74 de las variables disponibles, lo que permite generar árboles diferentes entre sí y combinar posteriormente sus predicciones.

Como medida interna del modelo, Random Forest reportó aproximadamente un 61.3% de varianza explicada. Sin embargo, para comparar su desempeño con los modelos anteriores se utilizan principalmente los resultados obtenidos sobre el conjunto de prueba, ya que este contiene películas que no participaron en el entrenamiento.

En el conjunto de prueba, Random Forest obtuvo un R^2 de 0.612, superando al 0.583 alcanzado por la regresión lineal. Esto indica que el modelo logra explicar aproximadamente el 61.2% de la variabilidad observada en `log_ingresos`. La mejora también se observa en las métricas de error. El RMSE disminuyó de 0.534 en la regresión lineal a 0.515 en Random Forest, mientras que el MAE pasó de 0.373 a 0.345. Ambos modelos presentan una mejora considerable respecto al modelo base, cuyo R^2 fue cercano a cero y cuyos errores fueron sustancialmente mayores.

Aunque la diferencia entre Random Forest y la regresión lineal no es muy amplia, Random Forest presenta el mejor desempeño en todas las métricas consideradas. Por esta razón, se selecciona como modelo principal para generar las estimaciones finales de ingresos y, posteriormente, calcular el ROI estimado y la clasificación de rentabilidad de cada película.

COMPARACIÓN FINAL DE MODELOS					
	Modelo	MSE	RMSE	MAE	R^2
1	Modelo base	0.6839908	0.8270374	0.6140709	-0.001541258
2	Regresión lineal	0.2849931	0.5338475	0.3729775	0.582695611
3	Random Forest	0.2652234	0.5149985	0.3449515	0.611643602


Una vez seleccionado Random Forest como el modelo con mejor desempeño, se analiza la importancia de las variables utilizadas durante el entrenamiento. El objetivo de esta etapa es identificar qué características aportan más información a la capacidad predictiva del modelo.

La función `importance()` permite obtener distintas medidas de importancia para cada predictor. En este análisis se utiliza `%IncMSE`, que representa cuánto aumenta el error cuadrático medio del modelo cuando se altera la información de una variable. Si al modificar una característica el error aumenta considerablemente, significa que el modelo dependía de esa variable para realizar sus predicciones.

A partir de esta medida, las variables se ordenan de mayor a menor importancia y se seleccionan las 25 con los valores más altos de `%IncMSE`. Esto permite concentrar el análisis en aquellas características cuya información resulta más relevante para la estimación de `log_ingresos`.

Resultados de importancia de variables

El análisis de importancia muestra que el presupuesto es la variable con mayor contribución predictiva dentro del Random Forest, con el valor más alto de %IncMSE (77.66). Le sigue el número de votos (62.10), lo que indica que ambas variables contienen una cantidad importante de información para estimar los ingresos de las películas. El año de estreno también presenta una importancia elevada (48.87), seguido por la pertenencia a una franquicia (33.20), la popularidad (29.37) y la calificación promedio (25.97). En conjunto, estos resultados muestran que el modelo utiliza información financiera, temporal y relacionada con la recepción del público para realizar sus estimaciones.



La duración presenta una importancia menor, aunque todavía aporta información al modelo. Entre las características de contenido aparecen algunos géneros, principalmente Ciencia ficción, Comedia y Acción, aunque con valores de importancia considerablemente inferiores a los observados para presupuesto, número de votos o año de estreno.

Estos resultados sugieren que las variables numéricas y algunas características generales de producción concentran la mayor parte de la capacidad predictiva del modelo, mientras que las variables específicas de contenido aportan información adicional, pero de menor magnitud.

Evaluación final: ingresos estimados, ROI y rentabilidad

Una vez seleccionado Random Forest como el modelo con mejor desempeño, sus predicciones se utilizan para construir una evaluación final película por película.

Primero se verifica que exista una predicción para cada observación del conjunto de prueba. Posteriormente, las predicciones generadas en escala logarítmica se transforman nuevamente a dólares mediante 10^x , obteniendo así un ingreso estimado para cada película.

A partir de este ingreso estimado y del presupuesto real se calcula un ROI predicho mediante la relación entre ingresos y presupuesto. Con este valor se aplica el mismo criterio utilizado previamente en el análisis: una película se clasifica como "Rentable" cuando su ROI estimado es superior a 2.5 y como "No rentable" cuando no supera este umbral.

También se calculan el error absoluto de ingresos y el error absoluto de ROI para conocer qué tan alejadas se encuentran las predicciones de los valores observados.

Finalmente, se construye una tabla comparativa que reúne, para cada película, el presupuesto, los ingresos reales y estimados, el ROI real y estimado, así como la clasificación real y predicha de rentabilidad. Esta tabla permite revisar de forma directa el comportamiento del modelo en casos individuales antes de realizar una evaluación global de la clasificación.

Evaluación de la clasificación de rentabilidad

Después de calcular el ROI estimado para cada película, se compara la clasificación predicha con la clasificación real mediante una matriz de confusión, que permite identificar cuatro posibles resultados: películas correctamente clasificadas como rentables, películas correctamente clasificadas como no

rentables, falsos positivos y falsos negativos. Los falsos positivos corresponden a películas que el modelo considera rentables cuando en realidad no superan el umbral establecido, mientras que los falsos negativos son películas realmente rentables que el modelo clasifica como no rentables.

A partir de esta matriz se calculan cuatro métricas de evaluación. El *Accuracy* representa la proporción total de clasificaciones correctas. La *Precision* indica qué proporción de las películas clasificadas como rentables realmente lo son. El *Recall* mide qué proporción de todas las películas realmente rentables logra identificar el modelo. Finalmente, el F1 combina Precision y Recall en una sola medida, permitiendo evaluar el equilibrio entre ambas.

Resultados de la clasificación de rentabilidad

Al aplicar el umbral de ROI superior a 2.5, la clasificación derivada de las predicciones del Random Forest obtuvo un Accuracy de alrededor del 76%. Esto significa que aproximadamente tres de cada cuatro películas del conjunto de prueba fueron clasificadas correctamente como rentables o no rentables.

La Precision fue de 76%, lo que indica que, cuando el modelo clasifica una película como rentable, aproximadamente tres de cada cuatro predicciones son correctas. El Recall fue menor, con un valor de 63%, lo que significa que el modelo logra identificar cerca de dos terceras partes de todas las películas que realmente fueron rentables.

El valor F1 de 70% refleja el equilibrio entre Precision y Recall. En conjunto, los resultados muestran que la clasificación presenta una capacidad útil para distinguir entre películas rentables y no rentables, aunque tiene una mayor dificultad para identificar todas las producciones que finalmente superan el umbral de rentabilidad.


Comparación entre ROI real y estimado

La comparación entre el ROI real y el ROI estimado permite observar el comportamiento de las predicciones del modelo en el conjunto de prueba. La línea diagonal representa una predicción perfecta, por lo que los puntos cercanos a ella corresponden a películas cuyo ROI fue estimado con mayor precisión.

La mayor concentración de observaciones se encuentra en niveles bajos e intermedios de ROI, donde las predicciones siguen de manera aproximada la tendencia de los valores reales. Sin embargo, conforme aumenta el ROI observado, varias películas se ubican por debajo de la línea de referencia, mostrando una tendencia del modelo a subestimar los niveles de rentabilidad más elevados.


Las líneas correspondientes al umbral de ROI de 2.5 permiten distinguir visualmente las clasificaciones correctas y los errores. Se observa una mayor presencia de falsos negativos que de falsos positivos, lo que coincide con los resultados obtenidos en la matriz de confusión y explica el menor valor de Recall.

En conjunto, la gráfica muestra que el modelo representa adecuadamente la tendencia general de rentabilidad, aunque presenta mayores dificultades para reproducir los casos extremos.



Visualización de la matriz de confusión

La matriz de confusión se transforma en una visualización tipo mapa de calor. Para ello, primero se convierte la matriz en una tabla que contiene el número de películas observadas en cada combinación entre resultado real y resultado predicho. En la gráfica, cada celda representa una combinación posible entre la clasificación real y la clasificación estimada por el modelo. El color de cada recuadro depende de la frecuencia registrada: tonos más oscuros indican un mayor número de películas, mientras que los tonos más claros corresponden a frecuencias menores. Además, el número exacto de observaciones se muestra dentro de cada celda para facilitar la lectura.



Esta representación permite identificar de forma inmediata los aciertos del modelo, ubicados en la diagonal principal, así como los errores de clasificación, localizados fuera de ella. En particular, permite distinguir visualmente las películas correctamente clasificadas como rentables y no rentables, así como los falsos positivos y falsos negativos.

La gráfica complementa las métricas previamente calculadas, ya que resume de manera visual la distribución de las predicciones correctas e incorrectas al aplicar el umbral de ROI superior a 2.5.


Comparación por rangos de ROI

Para complementar la clasificación binaria de rentabilidad, se agrupan los valores de ROI real y estimado en cinco rangos: menor a 1, entre 1 y 2.5, entre 2.5 y 5, entre 5 y 10 y mayor a 10.

Esta agrupación permite analizar con mayor detalle cómo se distribuyen las películas según distintos niveles de retorno sobre la inversión, en lugar de considerar únicamente si superan o no el umbral de 2.5. Posteriormente se cuenta cuántas películas pertenecen a cada rango tanto para el ROI real como para el ROI estimado. Ambas distribuciones se integran en una misma tabla con el objetivo de compararlas directamente.

Finalmente, se construye una gráfica de barras agrupadas que muestra, para cada intervalo de ROI, el número de películas observadas y el número estimado por el modelo. Esta visualización permite identificar en qué niveles de rentabilidad las predicciones reproducen mejor la distribución real y en cuáles existen mayores diferencias. De esta forma es posible evaluar si el modelo tiende a concentrar sus estimaciones en ciertos rangos o si presenta dificultades para representar películas con niveles de ROI particularmente bajos o elevados.

En conjunto, estos resultados muestran una tendencia del modelo a generar predicciones más moderadas y a reducir los valores extremos de ROI. Esto ayuda a explicar la presencia de falsos negativos observada anteriormente, ya que algunas películas con niveles altos de rentabilidad son estimadas en rangos inferiores.



Revisión de errores película por película

Para complementar las métricas generales del modelo, se analiza el error de predicción a nivel individual. El objetivo es identificar ejemplos en los que Random Forest estimó los ingresos con mayor precisión y otros en los que presentó diferencias más grandes respecto a los valores reales. El error se calcula utilizando la diferencia absoluta entre el logaritmo de los ingresos reales y el logaritmo de los ingresos estimados. Esta escala permite comparar de manera más equilibrada películas con niveles de recaudación muy diferentes, evitando que las producciones con ingresos extremadamente altos dominen el análisis únicamente por manejar cantidades mayores.

También se identifica si la clasificación de rentabilidad fue correcta, comparando la categoría real y la estimada para cada película. A partir del error logarítmico se seleccionan las cinco películas con las predicciones más cercanas y las cinco con las diferencias más grandes. Estos casos se integran en una sola base para observar ejemplos concretos del comportamiento del modelo.

Finalmente, los ingresos reales y estimados de estas películas se representan mediante una gráfica de barras. Debido a las grandes diferencias entre los niveles de recaudación, el eje de ingresos se presenta en escala logarítmica, lo que permite comparar de manera más clara películas con magnitudes económicas muy distintas. Esta revisión permite observar que el desempeño global del modelo puede variar entre películas individuales y ayuda a identificar tanto casos en los que las estimaciones fueron muy cercanas como situaciones en las que el modelo tuvo mayores dificultades.

Ejemplos de predicciones individuales

La comparación de casos individuales permite observar que el desempeño del modelo varía entre películas. En algunos casos, los ingresos estimados se encuentran muy próximos a los ingresos reales, mientras que en otros existen diferencias considerablemente mayores.

Los ejemplos fueron seleccionados utilizando el error absoluto en escala logarítmica, incluyendo cinco películas con las predicciones más cercanas y cinco con los mayores errores. De esta forma, la gráfica no pretende representar el desempeño promedio del modelo, sino mostrar ejemplos de situaciones en las que la estimación fue especialmente precisa o presentó mayores dificultades.



Conclusión del modelado

A partir de los ingresos estimados por Random Forest también fue posible calcular un ROI predicho y evaluar la rentabilidad utilizando el umbral de 2.5 definido en el análisis. Esta clasificación alcanzó una exactitud cercana al 76%, por lo que aproximadamente tres de cada cuatro películas fueron clasificadas correctamente como rentables o no rentables. Sin embargo, el Recall fue menor, alrededor del 63%, mostrando que el modelo presenta mayores dificultades para identificar todas las películas que realmente alcanzan niveles rentables.

El análisis de los errores permitió identificar una tendencia adicional: el modelo genera estimaciones más moderadas y tiene dificultades para reproducir los valores extremos. Esto se observa especialmente en las películas con ROI elevado, cuyos niveles de rentabilidad tienden a ser subestimados y desplazados hacia rangos intermedios. Por lo tanto, el modelo resulta útil para representar el comportamiento general de los ingresos y la rentabilidad dentro de la muestra analizada, pero sus estimaciones deben interpretarse con mayor cautela en producciones con resultados comerciales extraordinarios.

Finalmente, los resultados deben entenderse como relaciones predictivas dentro de la información disponible en TMDB (The Movie Database) y no como relaciones causales. Además, variables como popularidad, número de votos y calificación promedio se actualizan después del estreno, por lo que el modelo no representa estrictamente un sistema de pronóstico previo al lanzamiento de una película. A pesar de estas limitaciones, el ejercicio muestra que el aprendizaje supervisado permite integrar una gran cantidad de características y generar estimaciones útiles para analizar el desempeño comercial de las películas.

Conclusión general

Este proyecto permitió aplicar un proceso completo de ciencia de datos para analizar y predecir el desempeño comercial de las películas, desde la exploración y preparación de los datos hasta la construcción y evaluación de diferentes modelos de aprendizaje automático.

A partir del análisis exploratorio se identificó que variables como el presupuesto, la popularidad y el número de votos tienen una relación importante con los ingresos de las películas. Sin embargo, también se observó que el éxito comercial no depende de una sola característica, sino de la interacción entre diferentes variables.

Durante la etapa de modelado se probaron diferentes algoritmos y se comparó su desempeño mediante las métricas correspondientes. De acuerdo con los resultados obtenidos en este proyecto, Random Forest fue el modelo que presentó el mejor desempeño general, mostrando una mayor capacidad para identificar las relaciones entre las variables y realizar predicciones sobre los ingresos y el comportamiento del ROI. Una de las ventajas de Random Forest en este problema fue su capacidad para capturar relaciones no lineales e interacciones entre las variables, algo importante debido a la naturaleza compleja del comportamiento de los ingresos cinematográficos. Además, el análisis de importancia de variables permitió identificar cuáles características aportan más información al momento de realizar las predicciones.

El análisis del ROI complementó el estudio de los ingresos, ya que permitió evaluar el rendimiento de una película tomando en cuenta la relación entre lo invertido y lo obtenido. Los resultados mostraron que, aunque el modelo puede reproducir adecuadamente los patrones generales de los datos, existen mayores dificultades para predecir valores extremos, por lo que sus resultados deben interpretarse como estimaciones y no como valores exactos.

Los resultados demuestran que las técnicas de aprendizaje automático pueden ser herramientas útiles para analizar los factores asociados al éxito financiero de una película y generar predicciones a partir de sus características. No obstante, existen factores externos que no están completamente representados en el conjunto de datos, como las estrategias de marketing, las tendencias del público, la competencia en cartelera y otros elementos que también pueden influir en el desempeño de una producción.